

面向高考报考咨询的深圳北理莫斯科大学问答系统

NLP 大作业项目

2026 年 6 月 30 日

摘要

高校报考咨询同时具有事实性、时效性和个体化特征。通用对话模型能够生成流畅回答，但在招生章程、专业设置和历年分数线等问题上容易出现来源不明或事实过期的问题。本文构建了一个面向深圳北理莫斯科大学报考场景的中文问答系统，将官方网页抓取、结构化分数线查询、本科和研究生专业维度表、检索增强生成、本地 Qwen 角色提示词调优和轻量意图分类结合起来。系统以官方招生信息网和研究生招生信息网等资料为主要知识来源，将政策文本写入文档检索层，将分数线、单双学籍、证书、教学语言、招生人数、学费和学制等信息写入结构化表，并通过意图路由决定检索、表格查询、日常对话和澄清问题的调用路径。在当前版本中，意图分类器使用 56 条训练样本和 19 条测试样本，测试准确率为 0.947，宏平均 F1 为 0.905；系统评测集包含 61 条报考问题，路由准确率为 0.770，检索来源覆盖率为 1.000。结果表明，一个以证据约束为核心的小型 RAG 系统比直接微调小模型更适合强事实招生咨询任务。

1 Introduction

高考志愿填报是一类典型的高风险信息检索任务。考生和家长不仅需要知道学校和专业的基本情况，还需要理解不同年份、不同省份和不同科类下的录取数据。对于中外合作大学而言，培养模式、语言环境、专业设置和报考政策往往具有更强的学校特异性，普通搜索引擎或通用聊天机器人很难同时保证回答的完整性、可追溯性和边界表达。

近年来，检索增强生成 (retrieval-augmented generation, RAG) 被广泛用于知识密集型自然语言处理任务。其基本思想是先从外部知识库检索相关证据，再由生成模型组织回答，从而降低模型仅依赖参数记忆时的事实错误风险 [1]。Qwen 系列模型展示了中文和多语言生成能力，Qwen3 Embedding/Reranker 进一步提供了文本表示和重排能力，为本项目的检索和生成模块提供了可扩展的模型基础 [2, 3]。


本文的目标不是构造一个泛化聊天机器人，而是完成一个可复现的招生咨询系统。系统围绕深圳北理莫斯科大学报考场景展开，重点处理学校信息、招生政策、专业介绍、分数线查询、校园生活和报考建议等问题。与直接将抓取文本用于微调不同，本文将事实知识保留在可更新、可引用的数据层中，只使用轻量训练模块完成问题类型识别和查询路由。

2 Method

2.1 任务定义

给定用户的中文问题 q 和可选考生画像 p (省份、科类、分数、位次、意向专业)，系统需要输出回答 a 、问题类型 t 、引用来源集合 S 以及结构化记录 R 。结构化记录不仅包括分数线，还包括本科专业单双学籍、证书来源、教学语言、学费住宿费，以及硕士和博士专业的招生人数、学制和教学语言。当证据不足时，系统应返回澄清问题或缺失说明，而不是生成无来源的结论。

2.2 系统流程



2.3 数据层

数据层分为两类。第一类是官方网页和政策文本，包括本科招生信息网、招生章程、研究生招生简章、专业介绍和常见问题等页面。抓取脚本保存原始快照，并将 HTML 清洗为纯文本，再切分为可检索片段。第二类是结构化招生表，字段包括年份、省份、科类、批次、录取类型、专业组、最低分、最低位次、专业层次、单双学籍、证书、教学语言、招生人数、学费、学制和来源链接。对于学校官网未直接以结构化表发布的历史投档数据，系统保留第三方汇总来源和政府新闻来源标记，并在回答中提示最终以考试院和学校公布为准。

2.4 检索与回答生成

当前系统实现了轻量词项检索作为基础版本。用户问题被切分为中英文词项，系统对文档片段计算词项重叠分数，并返回带标题、链接和片段的来源证据。为处理最新通知类问题，系

统增加了受控联网搜索模块：当用户显式勾选联网搜索，或问题包含“最新”“联网”“现在”等触发词时，后端只搜索深北莫招生网、研究生招生网和学校官网等官方域名，并将网页标题、链接和摘要追加到证据集合中；若联网失败，则回退到本地资料库并提示边界。分数线、证书、教学语言和招生人数问题不依赖生成模型回答，而是优先进入结构化表查询。回答生成模块根据问题类型、检索片段、结构化记录和考生画像组织中文回答，并强制加入边界说明：系统不能保证录取，不能编造缺失分数线，也不能替代学校官方资料。系统同时提供本地 Qwen/OpenAI-compatible 接口位；当服务器配置 `QWEN_API_URL` 时，Qwen 仅用于非结构化证据类回答的语言组织；涉及分数线、证书、单双学籍、教学语言和招生人数的结构化事实仍由表格查询和规则模板直接生成，以避免模型改写数字或证书信息。当该环境变量未配置时，系统明确报告 `qwen_configured=false` 并使用规则化生成。

2.5 轻量模型训练

为体现 NLP 模型构建过程，本文训练了一个意图分类器，用于识别学校事实、招生政策、分数线查询、专业介绍、校园生活、奖助政策、就业深造、报考建议、日常对话和不支持问题等类别。分类器采用字符 n-gram TF-IDF 特征和逻辑回归模型。该模块不记忆招生事实，只参与路由决策；当模型不可用或置信度不足时，系统回退到关键词规则。对于“你是谁”“谢谢”“你会什么”“讲个笑话”等日常对话，系统不触发招生资料检索，也不交给生成模型自由发挥，而是使用受控模板以深北莫报考助手身份进行简短回复。

3 Result

3.1 系统实现结果

系统提供了一个 Web demo。页面左侧记录省份、科类、分数、位次、意向专业和联网搜索开关，中间为对话区域，右侧展示本地检索来源、联网搜索结果、分数线表格、专业证书和研究生招生记录。该布局将“回答”和“依据”放在同一工作流中，便于老师在演示时检查系统是否真正进行了检索、联网搜索和结构化查询。

3.2 意图分类结果

当前意图分类器的训练集规模为 56，测试集规模为 19。测试准确率为 0.947，宏平均 F1 为 0.905。该结果主要用于证明系统具有可训练的查询路由模块；由于训练集规模较小，本文不将其解释为通用语义理解能力。

3.3 系统评测结果

系统评测集覆盖学校事实、招生政策、分数线、本科专业证书、教学语言、研究生招生人数、校园生活、奖助政策、就业深造、报考建议、日常对话和拒答问题，共 61 条。当前路由准确率为 0.770，检索来源覆盖率为 1.000，平均回答长度为 1473.7 字符。错误案例主要来自两类问题：其一，问题同时包含多个意图，需要更细的多标签路由；其二，官方资料未覆盖的主观体验问题只能返回边界说明。

3.4 失败模式

系统的主要局限包括三点。第一，当前分数线表仍需要用官方历年录取数据补全，缺失字段不能由模型推断。第二，词项检索能够保证可运行性，但在同义表达和长问题上不如向量检索与重排。第三，报考建议依赖考生位次、专业偏好和当年招生计划，系统只能提供资料整理和风险提示，不能给出确定录取结论。

4 Conclusion

本文实现了一个面向深圳北理莫斯科大学报考咨询的中文问答系统。系统将招生事实保留在可更新、可追溯的数据层中，通过检索和结构化查询约束回答，再用轻量训练模块完成意图路由，并在服务器端接入本地 Qwen 小模型用于非结构化证据回答的语言组织。该设计适合课程项目的完整性要求，也避免了小模型微调在强事实场景下容易产生过期记忆和不可解释回答的问题。后续工作应继续扩展省份分数线覆盖，加入向量检索和重排模型，并扩大评测集以更稳定地衡量回答忠实性。

参考文献

- [1] Lewis, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems* (2020). <https://arxiv.org/abs/2005.11401>
- [2] Qwen Team. Qwen2.5 Technical Report (2024). <https://arxiv.org/abs/2412.15115>
- [3] Qwen Team. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models (2025). <https://arxiv.org/abs/2506.05176>
- [4] 深圳北理莫斯科大学招生信息网. 深圳北理莫斯科大学 2025 年夏季高考招生章程. <https://admission.smbu.edu.cn/info/1336/12222.htm>
- [5] 深圳北理莫斯科大学招生信息网. <https://admission.smbu.edu.cn/>
- [6] 深圳市政府网站. 深圳多所高校公布 2025 年广东省本科批次普通类投档情况. https://www.sz.gov.cn/cn/xxgk/zfxxgj/zwdt/content/post_12287337.html
- [7] 大学生必备网. 2025 深圳北理莫斯科大学录取分数线 (含 2023-2024 历年). <https://www.dxsbb.com/news/148133.html>